

Tarefa III:

Detecção de região saliente baseado em restrições globais.

Israel de Oliveira¹, Phellippe Pinheiro², Raphael Ruschel¹

¹PPGEE (Programa de Pós-graduação em Engenharia Elétrica)

²PPGC (Programa de Pós-graduação em Ciências da Computação)

Universidade Federal do Rio Grande do Sul

Introdução ao Processamento de Imagens (CMP165)

Prof. Jacob Scharcanski

31 de julho, 2017, Porto Alegre

M. M. Cheng, N. J. Mitra, X. Huang, P. H. S. Torr and S. M. Hu, "Global Contrast Based Salient Region Detection," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 37, no. 3, pp. 569-582, March 1 2015.

1 Introdução

2 Método proposto

- Contraste baseado em histograma.
- Borramento no espaço de cores.
- Contraste de região.


3 Resultados

- Métrica
- Exemplos

4 Conclusões

Introdução I

- O artigo escolhido [Cheng et al. 2015] apresenta uma proposta de segmentação de objetos em primeiro plano (*foreground*).
- O algoritmo é composto em três partes: 1) quantização e borramento baseado em cores, 2) **segmentação baseado num mapeamento entre bordas e seus respectivos pixels contidos (*graph-based*)** [*TÁ CERTO ISSO?]* e 3) seleção das regiões que compõem o objeto em primeiro plano.
- Avalia-se esse e outros métodos (clássicos e de estado da arte) para imagens aleatórias (sem ajuste de parâmetros baseado na imagem de entrada). Pensando na aplicação para o usuário final, o qual demanda imagens, inclusive, diferentes das imagens das bases de treino.
- Apresenta boa relação entre custo computacional e precisão (em comparação com métodos tradicionais).
- É inspirado na visão humana, a qual é altamente sensível ao contraste.



Contraste baseado em histograma. I

- Imagem original $I \in \mathbb{R}^{N_1 \times N_2}$:

$$S(I_k) = \sum_{I_i \in I} D(I_k, I_i) \quad (1)$$

$$S(I_k) = \sum_{i=1}^{N_1 N_2} D(I_k, I_i) \quad (2)$$

$D(\cdot)$: métrica de distância entre cores. É proposto pelos autores a utilização da distância entre cores no espaço CIE $L^*a^*b^*$ (CIELAB).

$$S(I_k) = S(c_l) \sum_{j=1}^n f_j D(c_l, c_j) \quad (3)$$

c_l e f_l : cor do pixel k e probabilidade da cor ocorre na imagem.

Contraste baseado em histograma. II

- Quantização reduz a quantidade de cores mantendo informação relevante para segmentação.
- Alternativas como o uso de luminância não apresenta igual redução quando comparada com a quantização.



Borramento no espaço de cores. I

- A quantização pode inserir artefatos. Para corrigir isso, é proposto uma suavização do mapa de cores (*color space smoothing*):


$$S'(c_l) = \frac{1}{(m-1)T} \sum_{i=1}^m (T - D(c_l, c_i)) S(c_l) \quad (4)$$

$$T = \sum_{i=1}^M D(c_l, c_i) \quad (5)$$


m : quantidade de vizinhos mais próximos da cor c_l .

- Aplica-se, então, à imagem com o mapeamento $S'(c_l)$ uma segmentação *graph-based* [45].

Without Color space Smoothing



With Color space Smoothing





Contraste de região. I

Para cada região segmentada (r_k):

$$S(r_k) = w_s(r_k) \sum_{r_k \neq r_i} e^{-\frac{D_s(r_k, r_i)}{\sigma_s^2}} w(r_i) D_r(r_k, r_i) \quad (6)$$

na qual, os termos são definidos:

$$w_s(r_k) = e^{-9d_k^2} \quad (7)$$


$$D_s(r_k, r_i) = \|C_{r_k} - C_{r_i}\|_2 \quad (8)$$

$$w(r_k) = \frac{N(r_k)}{N_1 N_2} \quad (9)$$

Com d_k sendo a distância média entre os pixels da região k e o centro da imagem e $N(r_k)$ o total de pixels dentro da região k .

$$D_r(r_a, r_b) = \sum_{i=1}^{n_a} \sum_{j=1}^{n_b} f(c_{ai}) f(c_{bj}) D(c_{ai}, c_{bj}) \quad (10)$$

Com n_k e $f(c_{ki})$: o total de cores distintas dentro da região k e a probabilidade da cor i em relação as demais cores na região k .



Our



Ground Truth



Original image



Error (Our - GndTr). SSIM = 0.99384




É utilizado como métrica a precisão no acerto para cada pixel:

$$P = \frac{\sum_{k=1}^{N_1 N_2} |\hat{G}_k - G_k|}{N_1 N_2}$$

Our




Ground Truth



Original image



Error (Our - GndTr). Precision = 0.96757



Our




Ground Truth



Original image



Error (Our - GndTr). Precision = 0.7902



Our




Ground Truth



Original image



Relative error $\|Our - GndTr\|/ \|1_{I_{sc}}\| = 0.033941$



Our



Ground Truth




Original image



Error (Our - GndTr). Precision = 0.89498



Our



Ground Truth



Original image



Error (Our - GndTr). Precision = 0.93227



Tabela: Precisão: Nosso(autores)

Média	d. p.	mín.	máx.
0,9044 (0,9250)	0,0777	0,5572	0,9997

Com 5472 imagens de MSRA10K (no artigo foi usada base completa: 10.000 imagens). Tempo total: 17,24 horas. MATLAB 8.3.0.532 (R2014a) com quatro processo em paralelo (4 *workers*), Ubuntu 16.04.2 LTS (Linux kernel 4.4.0-87-generic), Intel Xeon CPU E3-1241 v3 (4 cores físicos com 3.50GHz).

Conclusões I

- O artigo mostra que há muitos métodos sendo apresentados com um certo desempenho que não reflete quando aplicado ao cotidiano (usuários de celular, por exemplo).
- É possível obter bons resultados com baixa variedade de cores devido à correção de artefatos resultantes da quantização.
- Por ser uma análise baseada em histograma com baixa variedade de cores e levar em conta aspectos espaciais, o custo computacional tende a ser baixo (usando bem menos de 1s no processo completo, com o programa todo escrito em C++).
- Os resultados são significativamente sensíveis à segmentação em regiões. Não é robusto quanto a má detecção de bordas e quando há um número grande de regiões.
- A aplicação sugerida pelos autores para segmentação em regiões retorna valores diferentes quando executado mais de uma vez.

Obrigado pela vossa atenção.

-  CHENG, M. M. et al. Global contrast based salient region detection.
IEEE Transactions on Pattern Analysis and Machine Intelligence, v. 37,
n. 3, p. 569–582, March 2015. ISSN 0162-8828.